

Detección de Manipulación de Mercado mediante Localización Espectral en Redes de Correlación Filtradas de Criptoactivos

Andrés Jesús Ospino Stevenson*, David Hernando Sánchez Lombana*, Sergio Alejandro Velandia Rodríguez*, Juan Jacobo Rincón Ruiz* * Programa de Matemáticas Aplicadas y Ciencias de la Computación
Universidad del Rosario, Bogotá, Colombia
{davidh.sanchez, sergioa.velandia, andresj.ospino, juanj.rincon, juanja.rincon}@urosario.edu.co

Resumen—Este trabajo propone un método para detectar esquemas de *pump & dump* en mercados de criptoactivos usando teoría espectral de grafos. La idea central es modelar el mercado como una red donde los nodos son tokens y las aristas representan correlaciones entre sus precios. Primero filtramos el ruido de mercado con Teoría de Matrices Aleatorias (RMT), usando dos ventanas de tiempo: una larga para calibrar los parámetros del filtro y una corta para detectar anomalías. Luego reducimos la red para que no sea demasiado densa, usando un MST al que se añaden aristas calibradas por modularidad. Sobre la red resultante calculamos el *Inverse Participation Ratio* (IPR), que mide qué tan concentrada está la energía de cada modo de vibración de la red. La hipótesis es que cuando un grupo de tokens es manipulado coordinadamente, forma una comunidad artificial que se detecta como un aumento anómalo del IPR. Para evitar falsos positivos, comparamos el IPR observado contra el que produciría una red aleatoria con la misma estructura de conexiones (*Configuration Model*). La validación se realiza sobre ≈ 351 eventos confirmados del dataset de La Morgia *et al.* [4], usando datos de 1 minuto de la API pública de Binance para pares *SYM/BTC* durante 2021–2022.

Index Terms—Teoría de grafos, análisis espectral, Laplaciana normalizada, Teoría de Matrices Aleatorias, distancia de Mantegna, esparsificación MST, *Configuration Model*, criptoactivos, detección de manipulación de mercado, *pump and dump*, *Inverse Participation Ratio*.

I. INTRODUCCIÓN

Los mercados de criptoactivos son poco regulados y tienen baja liquidez, lo que los hace vulnerables a manipulación. Uno de los esquemas más comunes es el *pump & dump*: un grupo coordinado compra masivamente un token para inflar su precio y luego lo vende, dejando pérdidas a los inversores que entraron tarde [1]. Se estima que el 24 % de los tokens lanzados en 2022 tuvo características de este tipo de manipulación [5].

Los métodos actuales de detección analizan cada token por separado: buscan picos anómalos de precio o volumen [2], o usan modelos de aprendizaje automático [3]. El problema es que la manipulación coordinada deja una huella colectiva que estos enfoques no pueden ver: varios tokens que de repente se mueven juntos de forma artificial, formando una comunidad densa en la red de correlaciones.

Este trabajo propone detectar esa huella usando análisis espectral de grafos. Representamos el mercado como una red donde los nodos son tokens y las aristas reflejan qué

tan correlacionados están sus precios. Luego analizamos la estructura matemática de esa red para encontrar agrupaciones artificiales.

La herramienta central es el *Inverse Participation Ratio* (IPR), un concepto originado en física [6] que mide qué tan concentrada está la energía en un modo de vibración de la red. Trabajos previos lo usan de forma descriptiva sobre matrices de correlación [7], [9]; este trabajo propone usarlo por primera vez como detector de manipulación, con validación sobre eventos reales etiquetados.

II. DESCRIPCIÓN DEL PROBLEMA

En mercados de criptoactivos, la manipulación coordinada mediante esquemas de *pump & dump* representa un desafío significativo para la detección temprana de anomalías. En estos eventos, un grupo de actores acumula un activo de baja liquidez y luego induce de forma coordinada un aumento artificial de su precio para finalmente vender en el pico. Este proceso ocurre en escalas de tiempo cortas y suele dejar señales débiles antes de la fase de *pump*, lo que dificulta su identificación anticipada.

A diferencia de otros fenómenos financieros, estos eventos no se manifiestan únicamente en el comportamiento individual de un activo, sino en patrones colectivos. Múltiples tokens pueden exhibir movimientos sincronizados como resultado de estrategias coordinadas de acumulación, rotación de capital o manipulación cruzada. El problema central consiste en detectar, a partir de series temporales de precios, la existencia de un subconjunto desconocido de tokens cuyos retornos presentan correlación estadística atípica en una ventana temporal previa a un evento de *pump* —subconjunto no etiquetado a priori, de tamaño variable, cuyo impacto puede quedar oculto dentro del comportamiento agregado del mercado.

II-A. Contexto del mercado

Los mercados de criptoactivos funcionan las 24 horas, tienen miles de tokens activos y poca supervisión. La mayoría de estos tokens tienen una capitalización muy baja, lo que significa que un grupo con capital moderado puede mover su precio fácilmente. Los organizadores de un *pump & dump* coordinan la compra a través de canales de Telegram o

Discord, inflan el precio y venden antes de que los demás puedan reaccionar [5].

Este problema presenta tres dificultades fundamentales. Primero, las correlaciones estimadas en ventanas finitas están fuertemente contaminadas por ruido estadístico, lo que dificulta distinguir entre correlación genuina y fluctuaciones aleatorias. Segundo, el mercado de criptoactivos es altamente dinámico: las relaciones entre activos cambian rápidamente debido a factores externos (noticias, liquidez, choques de mercado), lo que complica la definición de una línea base estable. Tercero, los eventos de *pump & dump* ocurren en escalas temporales cortas —horas o pocos días—, lo que limita la cantidad de datos disponibles para estimar de forma robusta la estructura de correlación.

Un problema técnico importante es que en condiciones normales, casi todos los tokens se mueven juntos siguiendo a Bitcoin —lo que se llama el *modo de mercado global* [7]. Si no eliminamos esta correlación de fondo, la red de correlaciones queda tan densa que no se puede distinguir ninguna estructura: todo parece conectado con todo.

II-B. Pregunta central

Antes de que un *pump* sea visible en el precio, los organizadores acumulan posiciones de forma coordinada. Esta acumulación debería dejar una huella estructural en la red de correlaciones entre tokens: un subgrupo que de repente se mueve junto, de manera distinta al resto del mercado.

La pregunta que guía este trabajo es:

¿Es posible detectar la fase de acumulación previa a un pump & dump observando cambios en la distribución de localización espectral de la red de correlaciones entre tokens?

Responder esto requiere construir un modelo que formalice qué significa “localización espectral” y cómo medirla de forma robusta en redes dinámicas. Ese es el objetivo de las secciones V-A y V-B.

II-C. Limitaciones de los enfoques actuales

Los métodos que analizan precio y volumen de cada token por separado tienen dos problemas principales. Primero, generan muchas falsas alarmas: cualquier movimiento brusco legítimo puede parecerse a un *pump*. Segundo, no ven la coordinación entre tokens, que es justo donde está la huella de la manipulación.

Los métodos basados en grafos que existen se enfocan en otras cosas: detectar ciclos de arbitraje [12] o analizar flujos entre exchanges [14]. Si bien el IPR se ha calculado sobre matrices de correlación financiera antes [7], [9], ningún trabajo lo usa como detector de manipulación combinando: (i) filtrado de ruido con RMT antes de construir el grafo; (ii) estadísticos sobre todo el espectro, sin asumir en qué región aparece la anomalía; y (iii) validación sobre eventos confirmados con hora exacta. Esa es la contribución de este trabajo.

III. OBJETIVO GENERAL Y OBJETIVOS ESPECÍFICOS

III-A. Objetivo General

Desarrollar y validar un detector de la fase de acumulación en esquemas de *pump & dump* en criptoactivos, modelando el mercado como una red de correlaciones filtrada y aplicando teoría espectral de grafos —mediante la Laplaciana normalizada y el *Inverse Participation Ratio* (IPR)— para identificar patrones de coordinación artificial sobre eventos reales etiquetados.

III-B. Objetivos Específicos

1. Construir la red de correlaciones dinámica $G_t = (V, E, w)$, donde cada nodo es un token, cada arista tiene peso derivado de la distancia de Mantegna [8] sobre retornos logarítmicos, y la red evoluciona sobre ventanas deslizantes. Los datos de entrada son velas de 1 minuto recopiladas mediante la API pública de Binance (GET /api/v3/klines) para los ≈ 351 eventos del dataset de La Morgia *et al.* [4], pares SYM/BTC, período 2021–2022. Binance ofrece mayor cobertura histórica que datasets anteriores, reduciendo el problema de tokens que ya no existen.
2. Filtrar el ruido estadístico de C_t mediante RMT (límites de Marchenko-Pastur, ventana dual $T_{\text{cal}} = 720 \text{ h} / T_{\text{det}} = 48 \text{ h}$, reconstrucción $\tilde{C}$ según la ecuación (4)) y esparsificar la red resultante usando el *Árbol de Expansión Mínima* (MST) como esqueleto topológico, al que se añaden k aristas adicionales calibradas por modularidad para preservar la estructura de comunidades del grafo completo.
3. Aplicar teoría espectral de grafos sobre G_t : calcular la Laplaciana normalizada $\mathcal{L}_t$ del grafo esparsificado y obtener el perfil completo del *Inverse Participation Ratio* para todos los modos $k \geq 1$. No restringimos el análisis a ninguna región del espectro: la posición espectral de una anomalía transitoria no es predecible de antemano, a diferencia de los enfoques estáticos de detección de comunidades. Los estadísticos distribucionales que usamos son:

$$\text{IPR}_{\text{mean}}(t) = \frac{1}{N-1} \sum_{k=1}^{N-1} \text{IPR}_k(t),$$

$$\text{IPR}_{p90}(t) = \text{percentil}_{90}\{\text{IPR}_k(t) : k = 1, \dots, N-1\}.$$

Al no depender del orden de los eigenvalores, ambos estadísticos son inmunes al problema del *eigenvalue crossing*.

4. Definir el umbral de detección usando el *Configuration Model* [10] como punto de comparación. Usar simplemente un percentil histórico como umbral es problemático: un mercado agitado por una crisis externa (colapso de FTX en 2022, por ejemplo) puede elevar el IPR sin que haya manipulación. En cambio, para cada ventana t generamos $M = 10\,000$ redes aleatorias con la misma estructura de conexiones que G_t (misma secuencia de grados, aristas reasignadas al azar) y estimamos cuánto IPR produce ese ruido de fondo. Declaramos

una anomalía cuando $\text{IPR}_{p90}(t)$ supera el percentil 99.7 empírico de la distribución nula:

$$\text{IPR}_{p90}(t) > \hat{F}_{\text{nul}}^{-1}(0,997), \quad (1)$$

donde $\hat{F}_{\text{nul}}^{-1}$ es la función de cuantiles empírica de los $M = 10\,000$ valores simulados. Este umbral no paramétrico evita asumir normalidad en la distribución nula: el estadístico IPR_{p90} es un estadístico de orden sobre una métrica de red y su distribución bajo el Configuration Model puede ser asimétrica. La equivalencia con $\mu_{\text{nul}} + 3\sigma_{\text{nul}}$ se cumple solo bajo normalidad y se reportará como referencia, pero el criterio operativo es el percentil empírico. Esto controla por la densidad local de la red: un IPR alto no puede atribuirse simplemente a que la red sea densa, porque eso ya está capturado por el modelo nulo. Reportaremos resultados bajo el modelo estándar y bajo una versión con pesos permutados, para evaluar robustez.

5. Evaluar el detector sobre los ≈ 351 eventos confirmados del dataset [4] (pares SYM/BTC en Binance, 2021–2022). Por el severo desbalance de clases propio de la detección de anomalías, la métrica principal es el **PR-AUC** (área bajo la curva Precisión-Recall), complementada con el **F1-Score**. El ROC-AUC se reporta para comparabilidad con la literatura, pero no es la métrica de decisión porque los Verdaderos Negativos inflan su denominador de forma engañosa en datasets desbalanceados. Además, inspeccionaremos los eigenvectores localizados para verificar que los tokens con mayor peso en $\phi_{k*}(t)$ corresponden efectivamente a los tokens manipulados, dando interpretabilidad al resultado.

IV. MARCO TEÓRICO

IV-A. Grafos y análisis espectral

Un grafo $G = (V, E, w)$ es una estructura matemática compuesta por un conjunto de nodos V , un conjunto de aristas E y una función de peso $w : E \rightarrow \mathbb{R}$. En este trabajo los nodos representan tokens de criptoactivos y los pesos reflejan el grado de correlación entre sus precios.

La *Laplaciana normalizada* $\mathcal{L} = D^{-1/2}(D - A)D^{-1/2}$ tiene eigenvalores acotados en $[0, 2]$ independientemente de la distribución de pesos, lo que hace que los valores del IPR sean comparables entre ventanas de tiempo distintas —propiedad esencial para construir una serie temporal coherente del detector. La Laplaciana estándar $D - A$ no tiene esta propiedad: su espectro escala con el grado medio de la red, de modo que ventanas con distinta densidad de correlaciones producen rangos de eigenvalores incomparables. La matriz de transición de caminata aleatoria $D^{-1}A$ tampoco es simétrica, lo que impide garantizar que sus eigenvectores formen una base ortonormal y complica el cálculo del IPR [10].

La normalización por $D^{-1/2}$ sí amplifica la contribución de nodos periféricos (tokens con pocas aristas fuertes), pero este efecto es deseable en nuestro contexto: un token aislado que de repente forma correlaciones fuertes con un grupo es precisamente la señal que queremos detectar. El ruido que puede introducirse en nodos muy aislados queda controlado por el

filtrado espectral previo con RMT, que elimina correlaciones espurias antes de construir el grafo.

El *Inverse Participation Ratio* (IPR) de un eigenvector mide qué tan concentrada está su energía sobre los nodos. Un eigenvector *extendido* produce $\text{IPR} \approx N^{-1}$; uno *localizado* produce $\text{IPR} \gg N^{-1}$. Este concepto proviene de la física del estado sólido [6], donde se usa para estudiar la transición entre estados conductores (extendidos) y aislantes (localizados) en materiales desordenados.

IV-B. Esparsificación de grafos

Un grafo completo sobre N activos tiene $N(N - 1)/2$ aristas. Una red tan densa uniformiza los eigenvectores de la Laplaciana, llevando el IPR de todos los modos cerca de N^{-1} y borrando cualquier señal de localización.

El *Árbol de Expansión Mínima* (MST) conecta todos los nodos con exactamente $N - 1$ aristas de mínimo costo total, preservando las correlaciones más fuertes [8]. Tumminello *et al.* [11] demostraron que estructuras de filtrado similares retienen información estadísticamente significativa en mercados financieros. El MST se usa como esqueleto base al que se añaden aristas adicionales calibradas por modularidad, equilibrando parsimonia estructural con riqueza topológica.

IV-C. Mercados financieros como redes de correlación

Los retornos logarítmicos son la representación estándar del cambio de precio de un activo porque estabilizan la varianza y hacen comparables activos de distinto precio. La correlación de Pearson mide dependencia lineal y es el punto de partida estándar en la literatura de redes financieras [7], [8].

Sin embargo, los retornos de criptoactivos exhiben colas pesadas extremas y agrupamiento de volatilidad (*volatility clustering*), fenómenos que pueden inflar artificialmente la correlación de Pearson durante choques exógenos [1]. Medidas de dependencia basadas en rangos, como Spearman o Kendall, son más robustas a valores atípicos porque solo dependen del orden relativo de los retornos y no de su magnitud. No las adoptamos como métrica principal porque la RMT —que es el mecanismo de filtrado central del pipeline— está desarrollada teóricamente para matrices de correlación de Pearson; no existe un equivalente de Marchenko-Pastur para matrices de correlación de Spearman con las mismas propiedades analíticas. No obstante, la sensibilidad a este supuesto se evaluará empíricamente comparando los resultados del detector bajo Pearson y bajo Spearman como análisis de robustez.

Mantegna [8] propuso transformar las correlaciones en distancias mediante $d_{ij} = \sqrt{2(1 - C_{ij})}$, lo que define una métrica euclidiana sobre el espacio de activos y permite construir el MST con semántica geométrica clara.

En mercados de criptoactivos existe un fenómeno dominante: casi todos los tokens se mueven junto con Bitcoin. Esta covariación se manifiesta como un eigenvalor dominante de la matriz de correlación que corresponde al *modo de mercado global* [7]. Si no se elimina, enmascara cualquier estructura de comunidad más fina.

IV-D. Teoría de Matrices Aleatorias y estacionariedad

La RMT predice que, bajo correlaciones puramente aleatorias, los eigenvalores de una matriz de correlación $N \times N$ construida sobre series de longitud T caen dentro del intervalo de Marchenko-Pastur $[\lambda_-, \lambda_+]$, que depende únicamente del cociente $Q = N/T$ [7]. Los eigenvalores fuera de este intervalo contienen información genuina sobre la estructura del sistema.

La condición $T \gg N$ (equivalentemente, $Q \ll 1$) es necesaria para que la predicción teórica sea precisa. Con velas de 1 minuto, la ventana de calibración de $T_{\text{cal}} = 720$ h corresponde a $720 \times 60 = 43\,200$ observaciones. Para $N = 50$ tokens activos, el cociente es $Q = 50/43\,200 \approx 0,0012$, valor que satisface ampliamente la condición $Q \ll 1$ y justifica la aplicación de la distribución de Marchenko-Pastur. En cambio, la ventana de detección de $T_{\text{det}} = 48$ h produce solo 2880 observaciones, con $Q \approx 0,017$, donde el estimador de Pearson tiene sesgo significativo. La solución adoptada separa la estimación de los límites (ventana larga, RMT válida) de su aplicación sobre ventanas cortas.

Esta transferencia introduce un supuesto de *estacionariedad local*: que la estructura de ruido estimada en los 30 días previos es representativa de las siguientes 48 h. El mercado de cripto-activos sufre cambios de régimen bruscos que pueden violar este supuesto. Sin embargo, el umbral dinámico basado en el Configuration Model (véase Sección VI) mitiga parcialmente este problema: al recalibrarse en cada ventana de detección usando la topología local de G_t , el umbral absorbe cambios en el nivel de correlación agregado sin requerir estacionariedad global. La validez de la transferencia se verifica empíricamente mediante un análisis de sensibilidad descrito en la sección de solución propuesta.

IV-E. Modelos nulos en redes complejas

Detectar una anomalía requiere definir primero qué constituye el comportamiento normal. En redes complejas el *modelo nulo* estándar es el *Configuration Model* [10]: dado un grafo observado G con secuencia de grados $\{d_i\}_{i=1}^N$, el Configuration Model genera una familia de grafos aleatorios que preservan exactamente esa secuencia de grados pero con las aristas reasignadas uniformemente al azar.

Esta construcción tiene una propiedad crucial: al preservar la secuencia de grados, controla por la densidad local de la red. Un IPR alto no puede atribuirse simplemente a que la red sea densa o esté concentrada en pocos hubs — esas características ya están capturadas por el modelo nulo. Lo que el umbral detecta es un exceso de localización que no puede explicarse por la topología de grado sola.

El umbral de detección se define como el percentil 99.7 empírico de la distribución de IPR_{p90} sobre las M redes nulas generadas. Este criterio no paramétrico es preferible a $\mu_{\text{null}} + 3\sigma_{\text{null}}$ porque el estadístico IPR_{p90} —siendo un estadístico de orden sobre una métrica de red— puede seguir una distribución asimétrica bajo el Configuration Model. Asumir normalidad subestimaría el umbral cuando la distribución nula tiene cola derecha pesada, incrementando los falsos positivos.

Una limitación del Configuration Model puro es que destruye el coeficiente de clustering local al reasignar aristas al azar. Las redes financieras tienen alta transitividad natural: si el token A correlaciona fuertemente con B y B con C , es probable que A correlacione con C , formando triángulos. Un modelo nulo que no captura esta propiedad tiene un IPR_{p90} nulo sistemáticamente menor que el de la red real en condiciones no manipuladas, haciendo que el umbral del 99.7% sea demasiado permisivo e incrementando los falsos positivos.

Para cuantificar este efecto se comparará el Configuration Model puro con un modelo nulo de *rewiring local*: dado el grafo observado G_t , se intercambian repetidamente los extremos de pares de aristas elegidos al azar preservando la secuencia de grados y el coeficiente de clustering local dentro de una tolerancia del 5% [15]. Al preservar la transitividad de la red, este modelo nulo produce un umbral más conservador y reduce los falsos positivos atribuibles a la estructura natural de triángulos del mercado. Los resultados se reportan bajo ambos modelos nulos.

IV-F. Limitaciones del marco: coordinación artificial frente a choques legítimos

La hipótesis central de este trabajo es que la fase de acumulación de un *pump & dump* produce localización espectral anómala en la red de correlaciones. Sin embargo, no toda localización espectral implica manipulación. Un choque fundamental legítimo y localizado —como una noticia regulatoria favorable exclusivamente para el sector DeFi— haría que ese grupo de tokens formara una comunidad densa y transitoria, elevando IPR_{p90} de la misma forma que la manipulación.

El marco teórico no puede distinguir ambos casos usando solo información espectral. La diferenciación depende de dos elementos que están fuera del alcance de este trabajo: (i) información externa sobre eventos de mercado que permita etiquetar períodos de choque legítimo, y (ii) patrones temporales (duración, reversión brusca) que son distintos entre un *pump & dump* y un choque fundamental. Esta es una limitación conocida del enfoque y no invalida el detector; implica que en la evaluación empírica se reportarán los falsos positivos coincidentes con eventos externos identificables, separándolos de los errores atribuibles al modelo.

V. MODELAMIENTO DEL PROBLEMA

V-A. Formulación del problema de detección

Sea $r_i(t) = \ln P_i(t) - \ln P_i(t-1)$ el retorno logarítmico del token i en el período $[t-1, t]$. Sobre una ventana de tiempo de longitud T , representamos la dinámica conjunta del mercado mediante la matriz de correlación $C_t \in \mathbb{R}^{N \times N}$ con entradas:

$$C_{ij}(t) = \frac{\langle r_i r_j \rangle - \langle r_i \rangle \langle r_j \rangle}{\sigma_i \sigma_j}, \quad (2)$$

donde σ_i es la desviación estándar de los retornos del token i . Esta matriz captura el grado de dependencia estadística entre pares de tokens en cada ventana temporal.

Modelamos un evento de *pump & dump* como la aparición transitoria de un subconjunto de tokens $S \subset V$ (donde V

es el conjunto de nodos del grafo de correlaciones, definido formalmente en la Sección IV), con $|S| \ll N$, cuyos retornos presentan dependencia estadística anómala respecto al resto del mercado. La acumulación coordinada previa a un *pump* induce correlaciones elevadas dentro de S , generando una estructura colectiva que no está presente en condiciones normales.

Bajo esta perspectiva, el problema se formula como una tarea de detección: identificar ventanas temporales t en las que existe un subconjunto S tal que las correlaciones entre sus elementos son sistemáticamente mayores —o estructuralmente distintas— que las esperadas bajo un comportamiento no manipulado. Este enfoque no requiere conocer a priori qué tokens pertenecen a S , sino inferir su existencia a partir de patrones agregados en C_t .

V-B. Modelo formal

A partir de la matriz de correlación C_t definida en la ecuación (2), el pipeline de filtrado opera sobre el espectro de C_t para separar señal de ruido y construir la red de correlaciones.

El problema es que esta matriz está llena de ruido: la mayoría de las correlaciones no reflejan una relación real entre tokens, sino fluctuaciones aleatorias. Para separar señal de ruido aplicamos la Teoría de Matrices Aleatorias (RMT). Descomponemos $C_t = \sum_{k=1}^N \lambda_k \mathbf{v}_k \mathbf{v}_k^\top$ y usamos la distribución de Marchenko-Pastur [7], que predice el intervalo de eigenvalores del ruido puro:

$$\lambda_{\pm} = \sigma^2 \left(1 \pm \sqrt{Q} \right)^2, \quad (3)$$

donde $Q = N/T$ y σ^2 es la varianza promedio de los retornos. Los eigenvalores en $[\lambda_-, \lambda_+]$ son ruido y se descartan. El eigenvalor dominante λ_1 , que corresponde al modo de mercado global, también se elimina.

La RMT requiere $T \gg N$ para ser válida. Un *pump & dump* dura solo horas [4], lo que obliga a usar ventanas de detección cortas donde esa condición no se cumple. La solución es separar los dos pasos: estimar los límites con una ventana larga de calibración $T_{\text{cal}} = 720$ h (30 días) y aplicarlos sobre ventanas cortas de $T_{\text{det}} = 48$ h. La validez de la transferencia se verifica mediante bootstrap: se extraen $B = 1000$ ventanas de calibración no solapadas del histórico disponible, se calcula $\lambda_+^{(b)}$ en cada una, y se comprueba que la precisión del detector varía menos del 5% entre los percentiles 5 y 95 de esa distribución. Este procedimiento captura la variabilidad real de λ_+ bajo los distintos regímenes de volatilidad observados en el mercado, sin asumir un rango de perturbación arbitrario.

La matriz filtrada que nos queda es:

$$\tilde{C}_{ij} = \sum_{k \in \mathcal{S}} \lambda_k v_{ki} v_{kj}, \quad (4)$$

donde $\mathcal{S} = \{k : \lambda_k > \lambda_+, k \neq 1\}$ contiene solo los eigenvalores informativos, sin el ruido ni el modo de mercado.

Con esta matriz construimos la red. El peso de cada arista (i, j) se obtiene de la distancia de Mantegna [8]:

$$d_{ij}(t) = \sqrt{2 \left(1 - \tilde{C}_{ij}(t) \right)}, \quad (5)$$

con $w_{ij} = 2 - d_{ij}$: tokens más correlacionados tienen aristas más pesadas. Esta métrica tiene la ventaja de preservar tanto correlaciones positivas como negativas, a diferencia de simplemente truncar los valores negativos a cero.

Si usáramos todos los pares de tokens como aristas, la red sería demasiado densa: cada nodo conectado con todos los demás hace que los eigenvectores de la Laplaciana sean uniformes y el IPR quede cercano a N^{-1} para todos los modos, borrando cualquier señal de localización. Para evitar esto, reducimos la red en dos pasos: construimos el Árbol de Expansión Mínima (MST) sobre las distancias d_{ij} , que conecta todos los nodos con $N - 1$ aristas preservando las correlaciones más fuertes; luego añadimos las k aristas de mayor peso faltantes en cada nodo, con k elegido como el valor mínimo tal que la similitud del coseno promedio entre los primeros 20 eigenvectores del grafo completo y del grafo esparsificado supere $\bar{s}_\phi \geq 0.95$.

La conservación de la estructura espectral se verifica en dos niveles: (i) los primeros 20 eigenvalores antes y después de la reducción tienen correlación de Spearman > 0.9 ; (ii) $\bar{s}_\phi > 0.95$ por construcción. El segundo criterio es esencial porque el IPR depende de ϕ_{ki}^4 —por el teorema de Davis-Kahan, eigenvectores correspondientes a eigenvalores casi degenerados pueden rotar significativamente ante una perturbación aun cuando los eigenvalores apenas cambien. Verificar solo eigenvalores no garantiza la estabilidad del estadístico de detección.

Sobre el grafo reducido $G_t = (V, E, w)$ calculamos la Laplaciana normalizada:

$$\mathcal{L}_t = D_t^{-1/2} (D_t - A_t) D_t^{-1/2}, \quad (6)$$

donde A_t es la matriz de adyacencia y D_t la matriz diagonal de grados. Sus pares propios $\{\lambda_k, \phi_k\}_{k=0}^{N-1}$ satisfacen $0 = \lambda_0 \leq \lambda_1 \leq \dots \leq \lambda_{N-1} \leq 2$. El eigenvalor $\lambda_0 = 0$ corresponde al vector constante y se excluye del análisis.

Para cada eigenvector $k \geq 1$ calculamos el *Inverse Participation Ratio*:

$$\text{IPR}_k(t) = \sum_{i=1}^N \phi_{ki}^4, \quad (7)$$

donde ϕ_{ki} es la componente i del eigenvector k . Un valor $\text{IPR}_k \approx N^{-1}$ indica participación uniforme de todos los tokens (eigenvector extendido); un valor cercano a 1 indica concentración en un solo nodo. Para un grupo artificial de m tokens, el IPR escala como $\sim m^{-1}$.

La posición espectral donde aparece la localización de un grupo manipulado depende de cuántos tokens lo componen y cómo se conectan al resto de la red. Sin un modelo previo que lo indique, restringir el análisis a los primeros o últimos eigenvalores no está justificado.

El problema del eigenvalue crossing: Una forma ingenua sería seguir el IPR del eigenvector número k a lo largo del tiempo. El problema es que en redes dinámicas el orden de los eigenvalores cambia entre ventanas consecutivas: el eigenvector número 5 hoy puede corresponder a una estructura completamente distinta que el número 5 de mañana. Comparar $\text{IPR}_5(t)$ con $\text{IPR}_5(t+1)$ puede ser como comparar cosas distintas, produciendo una serie temporal sin sentido.

Solución: resumir todo el espectro: En lugar de seguir modos individuales, en cada ventana calculamos dos estadísticos sobre la distribución completa de IPR:

$$\text{IPR}_{\text{mean}}(t) = \frac{1}{N-1} \sum_{k=1}^{N-1} \text{IPR}_k(t), \quad (8)$$

$$\text{IPR}_{p90}(t) = \text{percentil}_{90}\{\text{IPR}_k(t) : k = 1, \dots, N-1\}. \quad (9)$$

Este estadístico no depende del orden de los eigenvalores, así que es inmune al problema del *eigenvalue crossing*. La elección del percentil 90 balancea sensibilidad y robustez: el promedio IPR_{mean} diluye la señal cuando la manipulación afecta a $m \ll N$ tokens — para $m = 5$ y $N = 50$, el modo localizado ($\text{IPR} \sim 1/5$) promediado con los $N - 2$ modos extendidos ($\text{IPR} \sim 1/N$) produce un promedio apenas un 4 % mayor que el baseline, indetectable; el IPR_{max} o percentiles extremos (p99) son más ruidosos ante modos esporádicamente localizados no relacionados con manipulación. Para un grupo de $m \geq 5$ tokens, el modo localizado cae sistemáticamente en el decil superior del espectro de IPR. La sensibilidad a esta elección se evalúa en el análisis de robustez comparando p80, p90, p95 y p99.

La hipótesis es la siguiente: cuando un grupo de tokens está siendo acumulado coordinadamente antes de un *pump*, forman una comunidad artificial en la red que hace que al menos un modo espectral se concentre en ellos. No necesitamos saber cuál modo es ese, solo detectar que existe un aumento anómalo en $\text{IPR}_{p90}(t)$.

Con este marco, la pregunta central planteada al inicio se formaliza como:

¿Puede el percentil 90 de la distribución del IPR de la Laplaciana normalizada de una red de correlaciones filtrada detectar la fase de acumulación previa a esquemas de pump & dump en criptoactivos?

Si ese aumento no aparece en los eventos confirmados, el resultado negativo también es informativo y publicable.

VI. SOLUCIÓN PROPUESTA

La solución que proponemos traduce la pregunta de investigación en un *pipeline* de cinco etapas encadenadas. Cada etapa resuelve una dificultad concreta identificada en la sección anterior: el ruido estadístico que contamina las correlaciones, la densidad excesiva que uniformiza el espectro, la inestabilidad del orden de los eigenvalores a lo largo del tiempo y el riesgo de confundir volatilidad agregada de mercado con manipulación coordinada. El detector no analiza tokens en aislamiento sino la huella colectiva que deja la coordinación artificial en la topología de la red.

VI-A. Etapa 1: Recolección y construcción de la matriz de correlación

Recolectamos velas de 1 minuto para los pares SYM/BTC involucrados en los ≈ 351 eventos confirmados del dataset de La Morgia *et al.* [4], usando la API pública de Binance (`GET /api/v3/klines`) para el período 2021–2022. Elegimos Binance porque sus datos históricos de este período tienen

cobertura sustancialmente mayor que la de datasets anteriores, lo que reduce el número de tokens que ya no existen o tienen series incompletas.

A partir de los precios de cierre calculamos los retornos logarítmicos $r_i(t) = \ln P_i(t) - \ln P_i(t-1)$ y sobre cada ventana deslizante de longitud T construimos la matriz de correlación de Pearson $C_t \in \mathbb{R}^{N \times N}$ según la ecuación (2). Esta es la representación de partida: cada entrada $C_{ij}(t)$ mide cuánto se mueven juntos los tokens i y j en esa ventana, sin discriminar todavía qué parte de esa covariación es información real y qué parte es ruido.

VI-B. Etapa 2: Filtrado espectral con ventana dual

El problema de usar C_t directamente es que la mayoría de sus entradas no reflejan relaciones genuinas entre tokens sino fluctuaciones estadísticas [7]. Además, el eigenvalor dominante concentra la variación conjunta de todos los tokens siguiendo a Bitcoin —el modo de mercado global— y enmascaría cualquier estructura de comunidad más fina.

Para separar señal de ruido aplicamos la Teoría de Matrices Aleatorias (RMT). La distribución de Marchenko-Pastur predice que, bajo la hipótesis de correlaciones puramente aleatorias, todos los eigenvalores caen en el intervalo $[\lambda_-, \lambda_+]$ definido en la ecuación (3), con $Q = N/T$ y σ^2 la varianza promedio de los retornos [7]. Los eigenvalores dentro de ese intervalo son ruido y se descartan; el eigenvalor más grande λ_1 (modo de mercado global) también se elimina.

Aquí surge un problema práctico: la RMT requiere $T \gg N$ para ser válida, pero un *pump & dump* dura solo horas [4], lo que obliga a usar ventanas de detección cortas donde esa condición no se cumple. La solución es separar los dos pasos: estimamos los límites $[\lambda_-, \lambda_+]$ con una ventana larga de calibración $T_{\text{cal}} = 720$ h (30 días, donde la RMT es estadísticamente válida) y los aplicamos directamente sobre ventanas cortas de detección de $T_{\text{det}} = 48$ h. Para verificar que la aproximación es aceptable, comprobamos que perturbar λ_+ en $\pm 15\%$ produce cambios en la precisión del detector menores al 5 %.

La matriz filtrada resultante $\tilde{C}$ se obtiene mediante la ecuación (4), donde $\mathcal{S} = \{k : \lambda_k > \lambda_+, k \neq 1\}$ retiene únicamente los eigenvalores informativos, eliminando tanto el ruido aleatorio como el modo de mercado global.

VI-C. Etapa 3: Construcción del grafo esparsificado

Con $\tilde{C}$ construimos el grafo de correlaciones usando la distancia de Mantegna [8] (ecuación (5)), con peso de arista $w_{ij} = 2 - d_{ij}$: tokens más correlacionados reciben aristas más pesadas. Esta métrica preserva tanto correlaciones positivas como negativas, a diferencia de truncar los valores negativos a cero.

Usar el grafo completo sobre todos los pares destruye la señal que queremos detectar: cuando cada nodo está conectado con todos los demás, los eigenvectores de la Laplaciana tienden a ser uniformes y el IPR queda cercano a N^{-1} para todos los modos, borrando cualquier indicio de localización. Para evitarlo reducimos la red en dos pasos. Primero construimos el Árbol de Expansión Mínima (MST) sobre las distancias d_{ij} ,




Figura 1. Pipeline de detección de *pump & dump*. Las Etapas 1–3 construyen y filtran la matriz de correlación; la Etapa 4 esparsifica el grafo con MST; la Etapa 5 aplica teoría espectral de grafos para obtener IPR_{p90} ; la salida compara contra el *Configuration Model*.

que conecta los N nodos con solo $N - 1$ aristas preservando las correlaciones más fuertes. Luego añadimos las k aristas de mayor peso faltantes en cada nodo, con k elegido para maximizar la modularidad de la red usando el algoritmo de Leiden [13], que garantiza comunidades bien conectadas y evita los problemas de comunidades desconectadas del algoritmo de Louvain. La elección de Leiden es importante porque la optimización de modularidad es NP-duro en general: Leiden obtiene soluciones de alta calidad en tiempo polinomial con resultados reproducibles dada una semilla fija. Verificamos que la estructura espectral se conserva comparando los primeros 20 eigenvalores antes y después de la reducción mediante correlación de Spearman ($\rho > 0,9$).

VI-D. Etapa 4: Perfil espectral del IPR robusto al eigenvalue crossing

Sobre el grafo reducido $G_t = (V, E, w)$ calculamos la Laplaciana normalizada $\mathcal{L}_t$ (ecuación (6)). Sus pares propios $\{\lambda_k, \phi_k\}_{k=0}^{N-1}$ satisfacen $0 = \lambda_0 \leq \lambda_1 \leq \dots \leq \lambda_{N-1} \leq 2$. Para cada eigenvector $k \geq 1$ calculamos el *Inverse Participation Ratio* (ecuación (7)) [6]. Un valor $IPR_k \approx N^{-1}$ indica participación uniforme de todos los tokens; un valor cercano a 1 indica concentración en un solo nodo. Para un grupo artificial de m tokens el IPR escala como $\sim m^{-1}$, lo que permite estimar el tamaño del grupo manipulado.

Una forma ingenua de monitorear el IPR sería seguir el eigenvector número k a lo largo del tiempo. Sin embargo, en redes dinámicas el orden de los eigenvalores cambia entre ventanas consecutivas: el eigenvector número 5 en t puede corresponder a una estructura completamente distinta del número 5 en $t + 1$. Comparar $IPR_5(t)$ con $IPR_5(t + 1)$ produciría una serie temporal sin sentido. Este *eigenvalue crossing* es inherente a perturbaciones transitorias como las que genera un *pump & dump*, donde la comunidad artificial aparece y desaparece en horas, y no puede resolverse simplemente restringiendo el análisis a los primeros modos como se hace en detección de comunidades estáticas.

La solución es no seguir modos individuales. En cada ventana resumimos la distribución completa del IPR con los estadísticos IPR_{mean} e IPR_{p90} definidos en las ecuaciones (8)–(9). Al no depender del orden de los eigenvalores, ambos son inmunes al *eigenvalue crossing*. IPR_{mean} captura el nivel promedio de concentración en toda la red; IPR_{p90} se fija en la

cola superior y detecta si existe algún modo muy localizado sin importar cuál sea. La hipótesis operativa es que cuando un grupo de tokens está siendo acumulado coordinadamente antes del *pump*, la comunidad artificial que forman hace que al menos un modo espectral se concentre sobre ellos, elevando $IPR_{p90}(t)$ por encima de lo que cabría esperar de una red sin manipulación.

VI-E. Etapa 5: Umbral dinámico mediante el Configuration Model

El último problema es definir cuándo un valor de $IPR_{p90}(t)$ es realmente anómalo. Usar un percentil histórico como umbral es insuficiente: un evento externo que agite todo el mercado —como el colapso de FTX en noviembre de 2022— puede elevar el IPR en toda la red sin que haya manipulación coordinada. Un umbral fijo capturaría ese episodio como una detección, generando exactamente el tipo de falso positivo que queremos evitar.

Para controlar este efecto usamos el *Configuration Model* [10] como punto de comparación ventana a ventana. Para cada G_t generamos $M = 10\,000$ redes aleatorias con la misma secuencia de grados pero con las aristas reasignadas uniformemente al azar, preservando la densidad local de la red pero destruyendo cualquier estructura de comunidad. Sobre cada red aleatoria calculamos IPR_{p90} y construimos la distribución nula empírica. Declaramos una anomalía cuando $IPR_{p90}(t)$ supera el umbral definido en la ecuación (1): el percentil 99.7 empírico de esa distribución. Este criterio no paramétrico evita asumir normalidad, ya que IPR_{p90} como estadístico de orden puede seguir una distribución asimétrica. El umbral es *local*: se recalibra en cada ventana, de modo que un mercado globalmente más correlacionado produce automáticamente una línea base más alta. Para evaluar robustez reportaremos resultados bajo el modelo estándar y bajo una variante con pesos de arista permutados aleatoriamente.

VI-F. Evaluación e interpretabilidad

El detector se evalúa sobre los ≈ 351 eventos confirmados del dataset [4] (pares SYM/BTC en Binance, 2021–2022). La ventana de detección se centra en las 48 h previas a la hora exacta de inicio de cada evento etiquetado.

Dado el severo desbalance de clases inherente a la detección de anomalías —los eventos de *pump & dump* representan

una fracción pequeña de las ventanas temporales totales en dos años de datos—, la métrica principal es el **área bajo la curva Precisión-Recall (PR-AUC)**, complementada con el **F1-Score**. Estas métricas son las estándar para problemas de detección de fraude con clases desbalanceadas porque no inflan el resultado con los Verdaderos Negativos, a diferencia del ROC-AUC. Adicionalmente se reporta ROC-AUC para comparabilidad con la literatura existente.

Como línea base para comparación usamos un detector de umbral sobre retornos: se declara anomalía si el retorno promedio de los tokens en la ventana supera $\mu_{\text{hist}} + 3\sigma_{\text{hist}}$, donde μ_{hist} y σ_{hist} se estiman sobre los 30 días previos. Este detector es representativo de los enfoques univariados actuales [2] y permite cuantificar el beneficio de incorporar estructura de red al análisis.

Más allá de las métricas agregadas, inspeccionaremos los eigenvectores localizados para verificar que los tokens con mayor peso en $\phi_{k^*}(t)$ —donde k^* es el modo que maximiza el IPR en la ventana de alerta— corresponden efectivamente a los tokens manipulados según el dataset. Esta verificación es importante por dos razones. Primero, da interpretabilidad al resultado: el detector no es una caja negra sino que señala los nodos específicos que generan la anomalía. Segundo, si el resultado agregado es negativo —es decir, si el IPR no logra separar eventos manipulados de períodos normales—, este análisis permite determinar si la señal existe pero el umbral no es suficientemente sensible, o si la manipulación en este conjunto de datos no produce la estructura espectral que la hipótesis predice. En ambos casos el resultado es informativo y publicable.

Cuadro I
HIPERPARÁMETROS DEL PIPELINE

Parámetro	Valor	Justificación
T_{cal}	720 h (30 d)	RMT válida con $T \gg N$
T_{det}	48 h	Duración típica de acumulación [4]
M	10 000 redes	≈ 30 valores en la cola del percentil 99.7
Umbral	$\hat{F}_{\text{null}}^{-1}(0,997)$	Percentil 99.7 empírico (no paramétrico)
Sens. RMT	$\pm 15\%$ en λ_+	Cambio en precisión $< 5\%$

REFERENCIAS

- [1] J. Xu y B. Livshits, *The Anatomy of a Cryptocurrency Pump-and-Dump Scheme*, en *Proc. 28th USENIX Security Symposium*, pp. 1609–1625, 2019.
- [2] J. Kamps y B. Kleinberg, *To the Moon: Defining and Detecting Cryptocurrency Pump-and-Dumps*, *Crime Science*, vol. 7, no. 18, 2018. DOI: [10.1186/s40163-018-0093-5](https://doi.org/10.1186/s40163-018-0093-5)
- [3] J. T. Hamrick et al., *An Examination of the Cryptocurrency Pump-and-Dump Ecosystem*, *Information Processing & Management*, vol. 58, no. 4, art. 102506, 2021. DOI: [10.1016/j.ipm.2021.102506](https://doi.org/10.1016/j.ipm.2021.102506)
- [4] M. La Morgia, A. Mei, F. Sassi y J. Stefa, *Pump and Dumps in the Bitcoin Era: Real Time Detection of Cryptocurrency Market Manipulations*, en *Proc. 29th IEEE ICCCN*, pp. 1–9, 2020. DOI: [10.1109/ICCCN49398.2020.9209660](https://doi.org/10.1109/ICCCN49398.2020.9209660)
- [5] M. La Morgia, A. Mei, F. Sassi y J. Stefa, *The Doge of Wall Street: Analysis and Detection of Pump and Dump Cryptocurrency Manipulations*, *ACM Transactions on Internet Technology*, vol. 23, no. 1, art. 11, 2023. DOI: [10.1145/3561300](https://doi.org/10.1145/3561300)

- [6] P. W. Anderson, *Absence of Diffusion in Certain Random Lattices*, *Physical Review*, vol. 109, no. 5, pp. 1492–1505, 1958. DOI: [10.1103/PhysRev.109.1492](https://doi.org/10.1103/PhysRev.109.1492)
- [7] V. Plerou, P. Gopikrishnan, B. Rosenow, L. A. N. Amaral y H. E. Stanley, *Universal and Nonuniversal Properties of Cross Correlations in Financial Time Series*, *Physical Review Letters*, vol. 83, no. 7, pp. 1471–1474, 1999. DOI: [10.1103/PhysRevLett.83.1471](https://doi.org/10.1103/PhysRevLett.83.1471)
- [8] R. N. Mantegna, *Hierarchical Structure in Financial Markets*, *The European Physical Journal B*, vol. 11, no. 1, pp. 193–197, 1999. DOI: [10.1007/s100510050929](https://doi.org/10.1007/s100510050929)
- [9] A. Nobi et al., *Random Matrix Theory and Cross-correlations in Global Financial Indices and Local Stock Market Indices*, *Journal of the Korean Physical Society*, vol. 62, no. 4, pp. 569–574, 2013. DOI: [10.3938/jkps.62.569](https://doi.org/10.3938/jkps.62.569)
- [10] M. E. J. Newman, *The Structure and Function of Complex Networks*, *SIAM Review*, vol. 45, no. 2, pp. 167–256, 2003. DOI: [10.1137/S003614450342480](https://doi.org/10.1137/S003614450342480)
- [11] M. Tumminello, T. Aste, T. Di Matteo y R. N. Mantegna, *A Tool for Filtering Information in Complex Systems*, *Proceedings of the National Academy of Sciences*, vol. 102, no. 30, pp. 10421–10426, 2005. DOI: [10.1073/pnas.0500298102](https://doi.org/10.1073/pnas.0500298102)
- [12] Q. Wang et al., *Cyclic Arbitrage in Decentralized Exchanges*, en *Companion Proc. Web Conference 2022*, pp. 12–19, 2022. DOI: [10.1145/3487553.3524201](https://doi.org/10.1145/3487553.3524201)
- [13] V. A. Traag, L. Waltman y N. J. van Eck, *From Louvain to Leiden: Guaranteeing Well-connected Communities*, *Scientific Reports*, vol. 9, art. 5233, 2019. DOI: [10.1038/s41598-019-41695-z](https://doi.org/10.1038/s41598-019-41695-z)
- [14] K. Sornak et al., *The Topology of Interbank Payment Flows*, *Physica A*, vol. 379, no. 1, pp. 317–333, 2007. DOI: [10.1016/j.physa.2006.11.093](https://doi.org/10.1016/j.physa.2006.11.093)
- [15] S. Maslov y K. Sneppen, *Specificity and Stability in Topology of Protein Networks*, *Science*, vol. 296, no. 5569, pp. 910–913, 2002. DOI: [10.1126/science.1065103](https://doi.org/10.1126/science.1065103)